Trabalho_2_SSC5974_Métodos_Computacionais_Aplicados_ao_Mercado_

June 30, 2025

Emanuel Victor da Silva Favorato - 12558151

[15]:
```
from sklearn import tree
from sklearn import metrics
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.neural_network import MLPClassifier
from datetime import datetime

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import yfinance as yf

sns.set(style='whitegrid')
```

[4]:
```
dados=pd.read_excel('Dados_Classes_Indices.xlsx', engine='openpyxl')
dados.set_index(keys = 'Data', inplace = True)
dados
```

[4]:
```
              USD       IBOV         IMAB       IPCA    SELIC-ACC  SELIC-META  \
Data
Set-2003   2.9234   16010.00   732.134779  10.520830   987.926836       19.84
Out-2003   2.8562   17982.00   749.921194  10.551340  1004.149186       18.85
Nov-2003   2.9494   20183.00   780.713506  10.587210  1017.640246       17.32
Dez-2003   2.8892   22236.00   811.970067  10.642263  1031.614995       16.33
Jan-2004   2.9409   21851.00   859.640824  10.723145  1044.691245       16.29
…             …          …            …          …            …
Dez-2023   4.8413  134185.24  9907.091003  32.333332  7915.548970       11.65
Jan-2024   4.9535  127752.28  9862.560678  32.469132  7992.068230       11.65
Fev-2024   4.9833  129020.02  9916.762551  32.738626  8056.021400       11.15
Mar-2024   4.9962  128106.10  9924.477803  32.791008  8123.021440       10.65
Abr-2024   5.1718  125924.19  9764.246642  32.915614  8195.106990       10.65
```

```
                SP500BR
Data
Set-2003   2911.618698
Out-2003   3001.037902
Nov-2003   3121.055080
Dez-2003   3212.559264
Jan-2004   3326.481399
…                  …
Dez-2023  23092.177979
Jan-2024  24002.927275
Fev-2024  25396.242291
Mar-2024  26251.783470
Abr-2024  26043.581542

[248 rows x 7 columns]
```

[5]:

```
dados_chg = dados.pct_change()
dados_chg.fillna(0, inplace=True)
dados_chg
```

[5]:

```
               USD      IBOV      IMAB    IPCA  SELIC-ACC  SELIC-META  \
Data
Set-2003  0.000000  0.000000  0.000000  0.0000   0.000000    0.000000
Out-2003 -0.022987  0.123173  0.024294  0.0029   0.016421   -0.049899
Nov-2003  0.032631  0.122400  0.041061  0.0034   0.013435   -0.081167
Dez-2003 -0.020411  0.101719  0.040036  0.0052   0.013733   -0.057159
Jan-2004  0.017894 -0.017314  0.058710  0.0076   0.012676   -0.002449
…              …         …         …       …          …           …
Dez-2023 -0.019086  0.053829  0.027507  0.0056   0.008945   -0.041152
Jan-2024  0.023176 -0.047941 -0.004495  0.0042   0.009667    0.000000
Fev-2024  0.006016  0.009923  0.005496  0.0083   0.008002   -0.042918
Mar-2024  0.002589 -0.007084  0.000778  0.0016   0.008317   -0.044843
Abr-2024  0.035147 -0.017032 -0.016145  0.0038   0.008874    0.000000

            SP500BR
Data
Set-2003  0.000000
Out-2003  0.030711
Nov-2003  0.039992
Dez-2003  0.029318
Jan-2004  0.035461
…              …
Dez-2023  0.024299
Jan-2024  0.039440
Fev-2024  0.058048
Mar-2024  0.033688
```

```
Abr-2024 -0.007931

[248 rows x 7 columns]
```

1 Alocação sistemática

Alocação em Classes

[6]:
```python
#Calculo dos índices acumulados em 12 meses (base 100)
dados_acc12 = (dados/dados.shift(12)-1)
```

[7]:
```python
#Criação do dataframe de alocação em classes (SP500BR e IMAB), de acordo com o␣
↪momentum de 12 meses
dados_aloc2 = dados[['SP500BR', 'IMAB']].pct_change()
dados_aloc2['IMAB-ACC12'] = dados_acc12['IMAB']
dados_aloc2['SP500BR-ACC12'] = dados_acc12['SP500BR']
dados_aloc2.fillna(0, inplace=True)
dados_aloc2['OPT-IMAB'] = 0

dados_aloc2['OPT-IMAB'] = np.argmin(dados_aloc2[['IMAB-ACC12',␣
↪'SP500BR-ACC12']].reset_index().drop(['Data'], axis=1).to_numpy(), axis=1)
dados_aloc2['OPT-SP500BR'] = 1-dados_aloc2['OPT-IMAB']

dados_aloc2[['OPT-IMAB', 'OPT-SP500BR']] = dados_aloc2[['OPT-IMAB',␣
↪'OPT-SP500BR']].shift(1)

#Cálculo das variações da alocação
dados_aloc2 = dados_aloc2.iloc[13:]
dados_aloc2['BEST-ALOC'] =␣
↪dados_aloc2['IMAB']*dados_aloc2['OPT-IMAB']+dados_aloc2['SP500BR']*dados_aloc2['OPT-SP500BR

#Cálculo do resultado acumulado da alocação
n_train = 124
data = dados
data['BEST-ALOC-ACC']=(1 + dados_aloc2['BEST-ALOC']).cumprod()
data = (data/data.iloc[n_train]).iloc[n_train:]

dados_aloc2
```

[7]:
```
           SP500BR      IMAB  IMAB-ACC12  SP500BR-ACC12  OPT-IMAB  \
Data
Out-2004  0.013269  0.009512    0.263393       0.075767       1.0
Nov-2004 -0.007145  0.011878    0.227978       0.027009       1.0
Dez-2004  0.003610  0.015071    0.198501       0.001358       1.0
Jan-2005 -0.036160  0.012081    0.145716      -0.067905       1.0
Fev-2005  0.007327  0.005474    0.135498      -0.063790       1.0
```

```
...              ...       ...        ...          ...          ...
Dez-2023  0.024299  0.027507   0.160543     0.152686       1.0
Jan-2024  0.039440 -0.004495   0.155336     0.154664       1.0
Fev-2024  0.058048  0.005496   0.146985     0.228311       1.0
Mar-2024  0.033688  0.000778   0.118095     0.257454       0.0
Abr-2024 -0.007931 -0.016145   0.078259     0.249074       0.0

          OPT-SP500BR  BEST-ALOC
Data
Out-2004          0.0   0.009512
Nov-2004          0.0   0.011878
Dez-2004          0.0   0.015071
Jan-2005          0.0   0.012081
Fev-2005          0.0   0.005474
...               ...        ...
Dez-2023          0.0   0.027507
Jan-2024          0.0  -0.004495
Fev-2024          0.0   0.005496
Mar-2024          1.0   0.033688
Abr-2024          1.0  -0.007931

[235 rows x 7 columns]
```

[8]:

```
data = 100*data
data[['IBOV', 'IMAB', 'SP500BR', 'BEST-ALOC-ACC']].plot(figsize=(18,6),␣
↪grid=True);
```

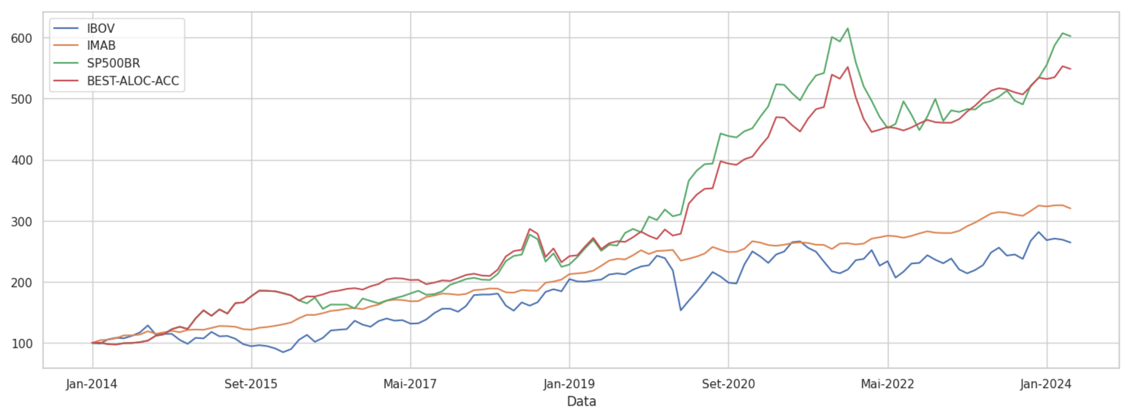

Preparando os dados para aprendizado de máquina

[9]:

```
#Cálculo do Momentum de 1, 4 e 12 meses para todos os índices
dados_mom1 = dados.copy()
dados_mom1.iloc[0:4] = 0
mom_period = 1
```

```
for ind in range(mom_period, len(dados.index)):
  dados_mom1.iloc[ind] = dados.iloc[ind]/dados.iloc[ind-mom_period]

dados_mom4 = dados.copy()
dados_mom4.iloc[0:4] = 0
mom_period = 4

for ind in range(mom_period, len(dados.index)):
  dados_mom4.iloc[ind] = dados.iloc[ind]/dados.iloc[ind-mom_period]

dados_mom12 = dados.copy()
dados_mom12.iloc[0:12] = 0
mom_period = 12

for ind in range(mom_period, len(dados.index)):
  dados_mom12.iloc[ind] = dados.iloc[ind]/dados.iloc[ind-mom_period]
```

[10]:
```
#Criando o data frame com informações para o algoritmo de aprendizado
dados_apr = dados_chg[['SP500BR', 'IMAB']].copy()

#Selecionando o Momentum do SP500BR para entrada do algoritmo
dados_apr['MOM1'] = dados_mom1['SP500BR']
dados_apr['MOM4'] = dados_mom4['SP500BR']
dados_apr['MOM12'] = dados_mom12['SP500BR']

#Criando as colunas com os resultados de alocação ideais (saída do algoritmo)
dados_apr['SP500BR-BUY'] = np.argmin(dados_apr[['SP500BR', 'IMAB']].
 ↪reset_index().drop(['Data'], axis=1).to_numpy(), axis=1)
dados_apr['IMAB-BUY'] = np.argmax(dados_apr[['SP500BR', 'IMAB']].reset_index().
 ↪drop(['Data'], axis=1).to_numpy(), axis=1)
```

[11]:
```
dados_apr
```

[11]:
```
          SP500BR      IMAB      MOM1      MOM4     MOM12  SP500BR-BUY  \
Data
Set-2003  0.000000  0.000000  0.000000  0.000000  0.000000            0
Out-2003  0.030711  0.024294  1.030711  0.000000  0.000000            1
Nov-2003  0.039992  0.041061  1.039992  0.000000  0.000000            0
Dez-2003  0.029318  0.040036  1.029318  0.000000  0.000000            0
Jan-2004  0.035461  0.058710  1.035461  1.142485  0.000000            0
…              …         …         …         …         …
Dez-2023  0.024299  0.027507  1.024299  1.040833  1.152686            0
Jan-2024  0.039440 -0.004495  1.039440  1.117827  1.154664            1
Fev-2024  0.058048  0.005496  1.058048  1.197363  1.228311            1
Mar-2024  0.033688  0.000778  1.033688  1.164449  1.257454            1
Abr-2024 -0.007931 -0.016145  0.992069  1.127810  1.249074            1
```

```
          IMAB-BUY
Data
Set-2003         0
Out-2003         0
Nov-2003         1
Dez-2003         1
Jan-2004         1
…              …
Dez-2023         1
Jan-2024         0
Fev-2024         0
Mar-2024         0
Abr-2024         0

[248 rows x 7 columns]
```

[12]:
```python
#Criando os vetores Numpy com as entradas (din) e saídas desejadas (dout)
#din = dados_apr[['MOM4', 'MOM12']].reset_index().drop(['Data'], axis=1).
 ↪to_numpy()
din = dados_apr[['MOM1', 'MOM4', 'MOM12']].reset_index().drop(['Data'], axis=1).
 ↪to_numpy()
dout = dados_apr[['SP500BR-BUY', 'IMAB-BUY']].reset_index().drop(['Data'],␣
 ↪axis=1).to_numpy()

print("Data samples:", dout.shape[0])
```

```
Data samples: 248
```

Utilizando Random Forest

[13]:
```python
#Número de samples para treinamento
n_train = 124

#Separando os dados em conjunto de treinamento e validação
train_in =   din[12:12+n_train]
train_out = dout[13:13+n_train]

val_in =   din[12+n_train:dout.shape[0]-1]
val_out = dout[13+n_train:dout.shape[0]]
```

[14]:
```python
# Treinamento com Árvores de decisão ou Random Forests

clf = RandomForestClassifier(random_state=1, max_depth=15)

clf.fit(train_in, train_out)
```

[14]:
```
RandomForestClassifier(max_depth=15, random_state=1)
```

[15]:
```
#Avaliando os resultados
y_pred = clf.predict(train_in)
print("Accuracy train:",metrics.accuracy_score(train_out, y_pred))

y_pred = clf.predict(val_in)
print("Accuracy validation:",metrics.accuracy_score(val_out, y_pred))

y_pred = clf.predict(din)
```

```
Accuracy train: 1.0
Accuracy validation: 0.5585585585585585
```

[16]:
```
#Copiando as saídas do algoritmo de aprendizado para o Data frame
dados_apr['SP500BR-BUY-APR'] = np.argmin(y_pred, axis=1)
dados_apr['IMAB-BUY-APR'] = np.argmax(y_pred, axis=1)

dados_apr['SP500BR-BUY-APR'] = dados_apr['SP500BR-BUY-APR'].shift(1)
dados_apr['IMAB-BUY-APR'] = dados_apr['IMAB-BUY-APR'].shift(1)

#Calculando o resultado acumulado do investimento utilizando aprendizado
dados_apr['APR-CHG'] = dados_apr['SP500BR'] * dados_apr['SP500BR-BUY-APR'] +
 ↪dados_apr['IMAB'] * dados_apr['IMAB-BUY-APR']
dados['APR-ACC'] = (1 + dados_apr['APR-CHG']).cumprod()
```

[17]:
```
# Gráfico de comparação SP500BR x IMAB x Aprendizado
dados = dados*100 / dados.iloc[n_train]
dados[['SP500BR', 'IMAB', 'APR-ACC']].iloc[n_train:].plot(figsize = (15,5))
```

[17]: <Axes: xlabel='Data'>

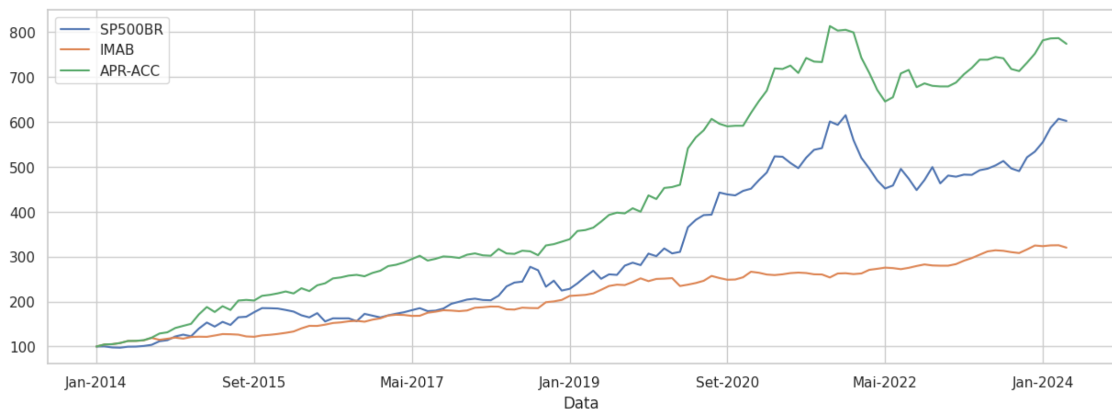

[18]:
```
# Retorno e volatilidade SP500BR x IMAB x Aprendizado
ref_data = n_train
```

```
periodo = int(len(dados.index[ref_data+1:])/12)
print("Periodo:", dados.index[ref_data+1], "-", dados.index[-1], '(',␣
↪periodo,')')

ret_acc = (dados[['SP500BR', 'IMAB', 'APR-ACC']].iloc[-1]/dados[['SP500BR',␣
↪'IMAB', 'APR-ACC']].iloc[ref_data])
print("Retorno acumulado:\n", ret_acc)
ret_aa = ((dados[['SP500BR', 'IMAB', 'APR-ACC']].iloc[-1]/dados[['SP500BR',␣
↪'IMAB', 'APR-ACC']].iloc[ref_data])**(1/periodo))-1
print("Retorno anualizado:\n", ret_aa)
vol_aa = dados_apr[['SP500BR', 'IMAB', 'APR-CHG']].iloc[ref_data+1:].std()*np.
↪sqrt(12)
print("Vol anualizada:\n", vol_aa)
```

```
Periodo: Fev-2014 - Abr-2024 ( 10 )
Retorno acumulado:
 SP500BR    6.021501
IMAB       3.201308
APR-ACC    7.737896
dtype: float64
Retorno anualizado:
 SP500BR    0.196659
IMAB       0.123396
APR-ACC    0.227050
dtype: float64
Vol anualizada:
 SP500BR    0.177137
IMAB       0.070247
APR-CHG    0.131956
dtype: float64
```

Utilizando Redes Neurais MLP

[19]:
```
# Treinamento com Redes Neurais MLP

#clf = MLPClassifier(random_state=1, hidden_layer_sizes=(20, ), max_iter=1000,␣
↪solver='adam', activation='relu')
clf = MLPClassifier(random_state=1, hidden_layer_sizes=(20, 5),␣
↪max_iter=1000000, solver='lbfgs', activation='tanh')
clf.fit(train_in, train_out)
```

[19]:
```
MLPClassifier(activation='tanh', hidden_layer_sizes=(20, 5), max_iter=1000000,
              random_state=1, solver='lbfgs')
```

[20]:
```
#Avaliando os resultados
y_pred = clf.predict(train_in)
print("Accuracy train:",metrics.accuracy_score(train_out, y_pred))
```

```python
y_pred = clf.predict(val_in)
print("Accuracy validation:",metrics.accuracy_score(val_out, y_pred))

y_pred = clf.predict(din)
```

```
Accuracy train: 0.7983870967741935
Accuracy validation: 0.5765765765765766
```

[21]:
```python
#Copiando as saídas do algoritmo de aprendizado para o Data frame
dados_apr['SP500BR-BUY-APR'] = np.argmin(y_pred, axis=1)
dados_apr['IMAB-BUY-APR'] = np.argmax(y_pred, axis=1)

dados_apr['SP500BR-BUY-APR'] = dados_apr['SP500BR-BUY-APR'].shift(1)
dados_apr['IMAB-BUY-APR'] = dados_apr['IMAB-BUY-APR'].shift(1)

#Calculando o resultado acumulado do investimento utilizando aprendizado
dados_apr['APR-CHG'] = dados_apr['SP500BR'] * dados_apr['SP500BR-BUY-APR'] +␣
  ↪dados_apr['IMAB'] * dados_apr['IMAB-BUY-APR']
dados['APR-ACC'] = (1 + dados_apr['APR-CHG']).cumprod()
```

[22]:
```python
# Gráfico de comparação SP500BR x IMAB x Aprendizado
dados = dados*100 / dados.iloc[n_train]
dados[['SP500BR', 'IMAB', 'APR-ACC']].iloc[n_train:].plot(figsize = (15,5))
```

[22]:
```
<Axes: xlabel='Data'>
```

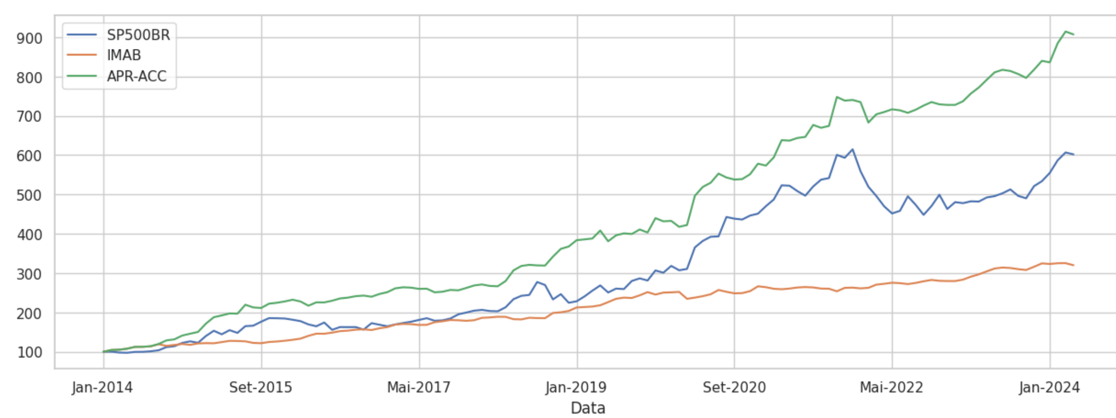

[23]:
```python
# Retorno e volatilidade SP500BR x IMAB x Aprendizado
ref_data = n_train
periodo = int(len(dados.index[ref_data+1:])/12)
print("Periodo:", dados.index[ref_data+1], "-", dados.index[-1], '(',␣
  ↪periodo,')')
```

```
ret_acc = (dados[['SP500BR', 'IMAB', 'APR-ACC']].iloc[-1]/dados[['SP500BR',␣
  ↪'IMAB', 'APR-ACC']].iloc[ref_data])
print("Retorno acumulado:\n", ret_acc)
ret_aa = ((dados[['SP500BR', 'IMAB', 'APR-ACC']].iloc[-1]/dados[['SP500BR',␣
  ↪'IMAB', 'APR-ACC']].iloc[ref_data])**(1/periodo))-1
print("Retorno anualizado:\n", ret_aa)
vol_aa = dados_apr[['SP500BR', 'IMAB', 'APR-CHG']].iloc[ref_data+1:].std()*np.
  ↪sqrt(12)
print("Vol anualizada:\n", vol_aa)
```

```
Periodo: Fev-2014 - Abr-2024 ( 10 )
Retorno acumulado:
 SP500BR    6.021501
IMAB       3.201308
APR-ACC    9.073810
dtype: float64
Retorno anualizado:
 SP500BR    0.196659
IMAB       0.123396
APR-ACC    0.246749
dtype: float64
Vol anualizada:
 SP500BR    0.177137
IMAB       0.070247
APR-CHG    0.124325
dtype: float64
```

2 Trading sistemático

[ ]:
```
!pip install ta
!pip install yfinance --upgrade --no-cache-dir

from ta.trend import MACD
from ta.momentum import RSIIndicator
import yfinance as yf
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
sns.set(style='whitegrid')
```

[29]:
```
start_date = '2014-01-01'
end_date   = '2024-04-30'
```

```
dados = yf.download('PETR4.SA', start=start_date, end=end_date,␣
↪interval='1d')[['Open', 'High', 'Low', 'Close', 'Volume']]
dados = dados.dropna()
```

```
/tmp/ipython-input-29-1867127844.py:4: FutureWarning: YF.download() has changed
argument auto_adjust default to True
  dados = yf.download('PETR4.SA', start=start_date, end=end_date,
interval='1d')[['Open', 'High', 'Low', 'Close', 'Volume']]
[*********************100%***********************]  1 of 1 completed
```

Considerando Moving Average Convergence Divergence (MACD) e Relative Strenght Index (RSI)

Mais informações em: https://ftmo.com/pt/os-11-principais-indicadores-tecnicos-que-podem-mudar-seu-trading-para-sempre/

[30]:
```
# Corrigir MultiIndex nas colunas
dados.columns = dados.columns.droplevel(0)  # Remove 'Price'
dados.columns.name = None  # Remove o nome da coluna

dados.columns = ['Open', 'High', 'Low', 'Close', 'Volume']
dados
```

[30]:
```
                 Open       High        Low      Close    Volume
Date
2014-01-02   4.939661   4.954062   4.795647   4.824450  17284800
2014-01-03   4.821569   4.833091   4.726520   4.752443  17837600
2014-01-06   4.738041   4.792766   4.654513   4.787006  20526500
2014-01-07   4.795647   4.847492   4.642994   4.654514  19052500
2014-01-08   4.686197   4.720760   4.648753   4.663155  15874600
…                 …          …          …          …         …
2024-04-23  32.796323  32.978525  32.447761  32.812164  35456900
2024-04-24  32.915146  33.263708  32.645804  32.661648  45388300
2024-04-25  32.796319  33.651873  32.542821  33.445908  66372400
2024-04-26  33.625091  34.024128  33.445930  33.918262  31899100
2024-04-29  33.779818  34.325443  33.649520  34.325443  27886000

[2566 rows x 5 columns]
```

[31]:
```
# MACD
macd_indicator = MACD(close=dados['Close'], window_slow=28, window_fast=14,␣
↪window_sign=9)
dados['macd'] = macd_indicator.macd()
dados['macd_signal'] = macd_indicator.macd_signal()

# RSI
rsi_indicator = RSIIndicator(close=dados['Close'], window=14)
dados['rsi'] = rsi_indicator.rsi()
```

[ ]:

```
# Estratégia com MACD: compra quando MACD cruza acima da linha de sinal, vende␣
↪quando cruza abaixo
dados['Saldo Trade'] = 100
comprado = 0
saldo = 100

for i in range(1, len(dados)):
    if dados['macd'].iloc[i-1] < dados['macd_signal'].iloc[i-1] and␣
↪dados['macd'].iloc[i] > dados['macd_signal'].iloc[i] and comprado == 0:
        comprado = 1
        val_compra = dados['Close'].iloc[i]
    elif dados['macd'].iloc[i-1] > dados['macd_signal'].iloc[i-1] and␣
↪dados['macd'].iloc[i] < dados['macd_signal'].iloc[i] and comprado == 1:
        comprado = 0
        saldo = saldo * (dados['Close'].iloc[i] / val_compra)

    dados['Saldo Trade'].iloc[i] = saldo
```

[33]:

```
dados_plot = dados[['Close', 'Saldo Trade']] / dados[['Close', 'Saldo Trade']].
↪iloc[0]
dados_plot.plot(figsize=(15,5), title="MACD Strategy vs Close Price");
print('Retorno acumulado com MACD:')
print(dados_plot.iloc[-1])
```

```
Retorno acumulado com MACD:
Close           7.114893
Saldo Trade    10.870685
Name: 2024-04-29 00:00:00, dtype: float64
```

[ ]:

```
# Estratégia com RSI: compra se RSI < 30 e vende se RSI > 70
dados['Saldo Trade'] = 100
comprado = 0
```

```
saldo = 100

for i in range(1, len(dados)):
    if dados['rsi'].iloc[i] < 30 and comprado == 0:
        comprado = 1
        val_compra = dados['Close'].iloc[i]
    elif dados['rsi'].iloc[i] > 70 and comprado == 1:
        comprado = 0
        saldo = saldo * (dados['Close'].iloc[i] / val_compra)

    dados['Saldo Trade'].iloc[i] = saldo
```

[35]:
```
dados_plot = dados[['Close', 'Saldo Trade']] / dados[['Close', 'Saldo Trade']].
 ↪iloc[0]
dados_plot.plot(figsize=(15,5), title="RSI Strategy vs Close Price");
print('Retorno acumulado com RSI:')
print(dados_plot.iloc[-1])
```

```
Retorno acumulado com RSI:
Close          7.114893
Saldo Trade    1.780573
Name: 2024-04-29 00:00:00, dtype: float64
```

Considerando Aprendizado de Máquina MLP e Random Forest com MACD e RSI

[36]:
```
# Initialize Action column
dados['Action'] = -1000

# Window-based buy/sell signal assignment (periodo_tam = 11 days)
periodo_inicio = 0
periodo_tam = 14
periodo_fim = periodo_inicio + periodo_tam
total_dados = dados.shape[0]
```

```
cont = 0

while cont < total_dados:
    # Prevent index overflow
    if periodo_fim > total_dados - 2:
        periodo_fim = total_dados - 2

    window_close = dados['Close'].iloc[periodo_inicio:periodo_fim]
    min_close = window_close.min()
    max_close = window_close.max()

    for i in range(periodo_inicio, periodo_fim):
        if dados['Close'].iloc[i] == min_close:
            dados.loc[dados.index[i], 'Action'] = 0  # Hold on min day
            dados.loc[dados.index[i + 1], 'Action'] = 1  # Buy next day
        elif dados['Close'].iloc[i] == max_close:
            dados.loc[dados.index[i], 'Action'] = 0  # Hold on max day
            dados.loc[dados.index[i + 1], 'Action'] = -1  # Sell next day
        elif dados['Action'].iloc[i] == -1000:
            dados.loc[dados.index[i], 'Action'] = 0  # Hold if no signal

    periodo_inicio = periodo_fim + 1
    periodo_fim = periodo_inicio + periodo_tam
    cont = periodo_fim

# Calculate MACD and RSI indicators
macd_indicator = MACD(close=dados['Close'], window_slow=26, window_fast=12,␣
 ↪window_sign=9)
dados['macd'] = macd_indicator.macd()
dados['macd_signal'] = macd_indicator.macd_signal()

rsi_indicator = RSIIndicator(close=dados['Close'], window=14)
dados['RSI'] = rsi_indicator.rsi() / 100.0  # normalize RSI

# Drop rows with NaNs generated by indicators
dados = dados.dropna().reset_index(drop=True)

# Features and target for ML
features = dados[['macd', 'macd_signal', 'RSI']].to_numpy()
target = dados['Action'].to_numpy()

print(f"Features shape: {features.shape}")
print(f"Target shape: {target.shape}")

# Train/test split (shift target by 1 for prediction of next day)
train_n = 1000
total_n = features.shape[0]
```

```
train_in = features[0:train_n]
train_out = target[1:train_n + 1]

test_in = features[train_n:total_n - 1]
test_out = target[train_n + 1:total_n]

print(f"Train in shape: {train_in.shape}")
print(f"Train out shape: {train_out.shape}")
print(f"Test in shape: {test_in.shape}")
print(f"Test out shape: {test_out.shape}")
```

```
Features shape: (2533, 3)
Target shape: (2533,)
Train in shape: (1000, 3)
Train out shape: (1000,)
Test in shape: (1532, 3)
Test out shape: (1532,)
```

[61]:

```
clf = MLPClassifier(solver='lbfgs', hidden_layer_sizes=(25, 10),␣
↪random_state=1, max_iter=200000, activation='tanh')

# Train the model
clf.fit(train_in, train_out)

# Evaluate on train
y_pred_train = clf.predict(train_in)
print(f"Training accuracy: {metrics.accuracy_score(train_out, y_pred_train):.
↪3f}")

# Evaluate on test
y_pred_test = clf.predict(test_in)
print(f"Test accuracy: {metrics.accuracy_score(test_out, y_pred_test):.3f}")

# Predict on all available features (aligned with dados)
y_pred_all = clf.predict(features)

# Add ML predictions to DataFrame
dados['ML-Action'] = y_pred_all

# Simulate trading results based on ML predictions
dados['Saldo'] = 0
saldo = 100
comprado = 0
val_neg = 0
trades = 0
trades_pos = 0
```

```python
media_pos = 0
media_neg = 0

for i in range(len(dados)):
    action = dados['ML-Action'].iloc[i]
    price = dados['Close'].iloc[i]

    if action == 1 and comprado == 0:
        val_neg = price
        comprado = 1
    elif action == 1 and comprado == -1:
        res_trade = val_neg / price - 1
        if res_trade > 0:
            trades_pos += 1
            media_pos += res_trade
        else:
            media_neg += res_trade
        saldo *= (1 + res_trade)
        trades += 1
        comprado = 0
    elif action == -1 and comprado == 0:
        comprado = -1
        val_neg = price
    elif action == -1 and comprado == 1:
        res_trade = price / val_neg - 1
        if res_trade > 0:
            trades_pos += 1
            media_pos += res_trade
        else:
            media_neg += res_trade
        saldo *= (1 + res_trade)
        trades += 1
        comprado = 0

    dados.loc[dados.index[i], 'Saldo'] = saldo

if trades_pos > 0:
    print(f"Trades total: {trades}, Trades positivos: {trades_pos} ({trades_pos/trades*100:.2f}%)")
    print(f"Média trades positivos: {media_pos/trades_pos*100:.2f}%, Média trades negativos: {media_neg/(trades - trades_pos)*100:.2f}%")
    print(f"Rent. buy and hold: {(dados['Close'].iloc[-1] / dados['Close'].iloc[0] - 1) * 100:.2f}%")
    print(f"Rent. ML trade: {(dados['Saldo'].iloc[-1] / dados['Saldo'].iloc[0] - 1) * 100:.2f}%")
else:
    print("Não foram feitos trades no período.")
```

```
# Plot equity curve
plt.figure(figsize=(15,5))
plt.title('Curva de capital (ML Trade vs Buy and Hold)')
plt.plot(dados['Saldo'], label='ML Trade')
plt.plot((dados['Close'] / dados['Close'].iloc[0]) * 100, label='Buy and Hold')
plt.legend()
plt.show()
```

```
/usr/local/lib/python3.11/dist-
packages/sklearn/neural_network/_multilayer_perceptron.py:546:
ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. OF F,G EVALUATIONS EXCEEDS LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
  self.n_iter_ = _check_optimize_result("lbfgs", opt_res, self.max_iter)
/tmp/ipython-input-61-3939971659.py:61: FutureWarning: Setting an item of
incompatible dtype is deprecated and will raise an error in a future version of
pandas. Value '121.27934216239453' has dtype incompatible with int64, please
explicitly cast to a compatible dtype first.
  dados.loc[dados.index[i], 'Saldo'] = saldo
```

```
Training accuracy: 0.885
Test accuracy: 0.706
Trades total: 25, Trades positivos: 15 (60.00%)
Média trades positivos: 39.65%, Média trades negativos: -10.16%
Rent. buy and hold: 744.61%
Rent. ML trade: 3354.08%
```

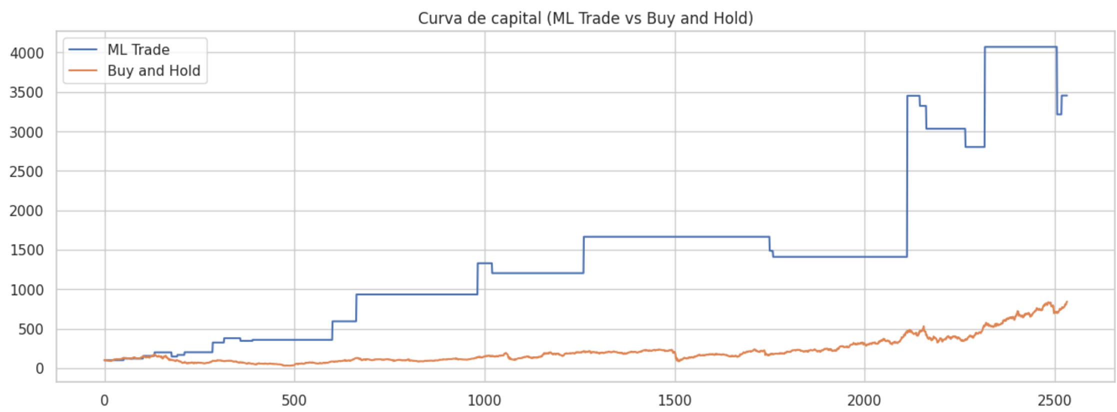

[59]:
```
clf = RandomForestClassifier(random_state=1, max_depth=18)

# Train the model
```

```
clf.fit(train_in, train_out)

# Evaluate on train
y_pred_train = clf.predict(train_in)
print(f"Training accuracy: {metrics.accuracy_score(train_out, y_pred_train):.
 ↪3f}")

# Evaluate on test
y_pred_test = clf.predict(test_in)
print(f"Test accuracy: {metrics.accuracy_score(test_out, y_pred_test):.3f}")

# Predict on all available features (aligned with dados)
y_pred_all = clf.predict(features)

# Add ML predictions to DataFrame
dados['ML-Action'] = y_pred_all

# Simulate trading results based on ML predictions
dados['Saldo'] = 0
saldo = 100
comprado = 0
val_neg = 0
trades = 0
trades_pos = 0
media_pos = 0
media_neg = 0

for i in range(len(dados)):
    action = dados['ML-Action'].iloc[i]
    price = dados['Close'].iloc[i]

    if action == 1 and comprado == 0:
        val_neg = price
        comprado = 1
    elif action == 1 and comprado == -1:
        res_trade = val_neg / price - 1
        if res_trade > 0:
            trades_pos += 1
            media_pos += res_trade
        else:
            media_neg += res_trade
        saldo *= (1 + res_trade)
        trades += 1
        comprado = 0
    elif action == -1 and comprado == 0:
        comprado = -1
        val_neg = price
```

```
    elif action == -1 and comprado == 1:
        res_trade = price / val_neg - 1
        if res_trade > 0:
            trades_pos += 1
            media_pos += res_trade
        else:
            media_neg += res_trade
        saldo *= (1 + res_trade)
        trades += 1
        comprado = 0

    dados.loc[dados.index[i], 'Saldo'] = saldo

if trades_pos > 0:
    print(f"Trades total: {trades}, Trades positivos: {trades_pos} ({trades_pos/
↪trades*100:.2f}%)")
    print(f"Média trades positivos: {media_pos/trades_pos*100:.2f}%, Média␣
↪trades negativos: {media_neg/(trades - trades_pos)*100:.2f}%")
    print(f"Rent. buy and hold: {(dados['Close'].iloc[-1] / dados['Close'].
↪iloc[0] - 1) * 100:.2f}%")
    print(f"Rent. ML trade: {(dados['Saldo'].iloc[-1] / dados['Saldo'].iloc[0]␣
↪- 1) * 100:.2f}%")
else:
    print("Não foram feitos trades no período.")

# Plot equity curve
plt.figure(figsize=(15,5))
plt.title('Curva de capital (ML Trade vs Buy and Hold)')
plt.plot(dados['Saldo'], label='ML Trade')
plt.plot((dados['Close'] / dados['Close'].iloc[0]) * 100, label='Buy and Hold')
plt.legend()
plt.show()
```

```
Training accuracy: 0.998
Test accuracy: 0.803
Trades total: 78, Trades positivos: 71 (91.03%)
Média trades positivos: 18.06%, Média trades negativos: -15.48%
Rent. buy and hold: 744.61%
Rent. ML trade: 2258138.74%
```

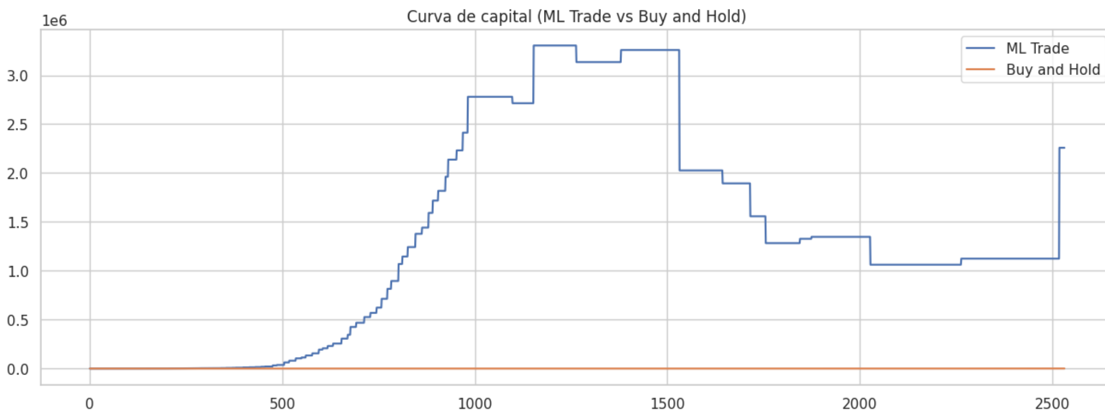
Curva de capital (ML Trade vs Buy and Hold)
1e6
3.0
2.5
2.0
1.5
1.0
0.5
0.0
0
500
1000
1500
2000
2500
ML Trade
Buy and Hold